Entrega 4: Contrato de dados, repositório e baseline

Aprendizagem de Máquina Supervisionada | UFPB/CCSA | Projeto aplicado de extensão, 2026.2

Equipe	Vítor Batista, Marcello Siqueira e Ricardo César
Demandante	Frederico Torres (LAPAE – Laboratório de Patologia e Análises Especializadas, João Pessoa/PB)
Tema do projeto	Previsão da quantidade mensal de exames que chegam ao laboratório, para apoiar o planejamento do tempo e da capacidade de trabalho
Repositório	https://github.com/vitorblm31/lapae
Notebook de auditoria	[inserir link do notebook, dentro do repositório]
Legenda de marcação	**[F]** fato relatado pelo demandante **[H]** hipótese ou decisão da equipe **[L]** lacuna ou pendência

Estado da entrega. Em virtude da mudança de tema do projeto (previsão do volume mensal de exames), a equipe ainda não tem os dados em mãos para executar o código: os relatórios do demandante não haviam chegado na data desta redação. Por isso o contrato de dados, o diagnóstico de vazamento, a estratégia de partição, a definição dos baselines e o plano de pré-processamento estão fechados neste documento, mas o relatório de qualidade e o valor numérico da métrica inicial dependem da primeira carga e estão marcados como pendentes **[L]**. Nenhum número foi estimado ou inventado. O pipeline (limpeza, variáveis, partição, pré-processador e baselines) já foi construído e testado com dados sintéticos, identificados como demonstração (seção 2.3). Os fatos vêm da escuta de 20/10/2026 (Entrega 3).

1. Contrato de dados

Registrado antes de qualquer tratamento, com base na escuta de 20/10/2026.

Item	Registro
Chave e unidade	**[H]** Chave composta (unidade, mês), em que unidade é a policlínica ou USF que envia exames ao laboratório e mês é o ano-mês de chegada. Uma linha = a quantidade de exames de uma unidade em um mês. **[L]** Códigos de unidade usados no sistema: a confirmar.
Granularidade	**[F]** Frederico organiza o trabalho do laboratório no início de todo mês. **[H]** Por isso a granularidade é mensal, e por unidade porque o demandante terá os números de cada policlínica e USF. Se as séries por unidade forem curtas, a alternativa é o total mensal do laboratório.
Cobertura	**[F]** Histórico de 1 ano no sistema; outubro é o mês com mais exames; a equipe terá acesso aos números de cada policlínica e USF e aos municípios cobertos pelo laboratório quando o demandante enviar os relatórios. **[L]** Período exato (primeiro e último mês), número de unidades, lista de municípios e tipos de exame incluídos: a confirmar na primeira carga.
Alvo	**[F]** A quantidade de exames e a data de chegada ficam registradas no sistema do laboratório. **[H]** Definição operacional: número de exames com data de chegada dentro do mês-calendário, por unidade. **[H]** Disponível ao fim do mês. **[L]** Existência de retificações posteriores à contagem: a confirmar.
Corte temporal	**[F]** A previsão seria feita no início do mês, quando Frederico organiza o trabalho. **[F]** O demandante informou um corte de 4 dias. **[L]** O que os 4 dias medem (defasagem de registro ou antecedência necessária) ainda não está claro. **[H]** Regra provisória: só entram informações com data de chegada até o último dia do mês anterior, e a regra será revista quando o significado dos 4 dias for confirmado.
Atualização	**[L]** Frequência de atualização do sistema na origem: a confirmar. **[H]** Como os dados chegam por relatórios enviados pelo demandante, a base do projeto será um retrato com data de recebimento registrada; novas cargas serão tratadas como nova versão.
Restrições	**[F]** O demandante permitiu registrar o necessário para o projeto e as unidades terão números disponíveis para a equipe. **[H]** Trabalhar apenas com contagens agregadas por unidade e mês, sem qualquer identificação de paciente, por se tratar de dados de saúde (LGPD). **[L]** Autorização formal, base legal e usos vedados: a confirmar. Relatórios originais não são versionados no repositório.

2. Repositório, reprodutibilidade e fluxo de trabalho

2.1 Estrutura do repositório

Caminho	Conteúdo e regra
`dados/bruto/`	Relatórios originais, nunca editados. Como são dados de saúde de terceiros, não são versionados: ficam fora do Git e o repositório traz instruções de obtenção (quem envia, formato, data de recebimento) e uma amostra anonimizada.

Caminho	Conteúdo e regra
`dados/processado/`	Base analítica unidade × mês, gerada pelo notebook.
`notebooks/`	01_auditoria.ipynb (inspeção, qualidade, contagens antes e depois) e 02_baseline.ipynb (partição, baselines e métrica).
`src/`	Funções reutilizadas: carga, limpeza, validações de contagem, construção de defasagens, partição, baseline e métricas.
`tests/`	Testes automáticos do pipeline (pytest), com dados sintéticos.
`docs/`	Dicionário de dados, memória da escuta, Canvas de ML e este relatório.
`README.md`	Problema, decisão, alvo, fontes e como executar.
`requirements.txt`	Dependências com versões fixadas, geradas do ambiente em que o notebook foi executado.

Reprodutibilidade. O notebook roda do início ao fim e gera a base processada, sem edição manual. Os caminhos são relativos à raiz do repositório, nunca absolutos. A semente aleatória é fixa e o ambiente (versão do Python e dependências) é declarado. Mapeamentos feitos à mão (por exemplo, de-para de nomes de unidade) ficam em arquivo versionado dentro de docs/ ou dados/, não no notebook. Senhas, tokens, dados pessoais e documentos internos não são versionados.

2.2 Fluxo mínimo aplicado ao projeto

Etapa	O que será feito neste projeto
1. Obter	Receber os relatórios do demandante; registrar data de recebimento, nome e versão do arquivo e quem enviou.
2. Preservar	Guardar os originais sem alteração, fora do Git, com registro de tamanho e data; o notebook só lê, nunca grava em dados/bruto/.
3. Inspecionar	Dimensões, tipos, chaves, categorias de unidade e município, ausências e duplicidades, com contagens e chaves únicas.
4. Limpar	Normalizar nomes de unidade e município, datas e códigos, com de-para versionado.
5. Transformar	Agregar por unidade e mês, montar a grade completa unidade × mês e criar defasagens e média móvel apenas com meses anteriores.
6. Validar	Comparar contagens e totais antes e depois de cada filtro, junção e agregação; reconciliar a soma por unidade com o total do período.
7. Particionar	Separar treino, validação e teste por ordem temporal (seção 5).
8. Referenciar	Calcular os baselines no recorte de validação e registrar a métrica inicial.

2.3 Verificações executadas sem os dados reais

Com os relatórios ainda não recebidos, o pipeline foi construído em `src/` e verificado com dados sintéticos (`src/demo.py`), com problemas injetados de propósito: duplicatas, datas inválidas e grafias diferentes da mesma unidade. Os dados sintéticos servem para provar que o código está correto; **nenhum número calculado com eles é resultado do projeto**. Ambiente de referência: Python 3.13, com dependências fixadas em `requirements.txt`. Em cópia limpa do repositório, os 8 testes automáticos passaram e os notebooks 01 e 02 executaram em ordem, do início ao fim, sem erros.

Item da verificação	Situação	O que foi feito e evidência
Dados originais preservados ou obteníveis de novo	**Feito**	dados/bruto/LEIAME.md traz as instruções de obtenção e o registro de recebimento; o código só lê essa pasta; o .gitignore impede versionar os originais. Os relatórios em si ainda não foram recebidos.
Notebook executa em ordem, sem intervenção manual	**Feito em demonstração**	01_auditoria e 02_baseline executam do início ao fim a partir de cópia limpa, sem erros. Com os relatórios reais: pendente.
Sem caminhos absolutos	**Feito**	Todos os caminhos partem da raiz do repositório (pathlib). Um teste varre src/ e notebooks/ em busca de caminhos absolutos.
Tipos, unidades, categorias e chaves verificados	**Depende dos dados**	O notebook 01 já traz a inspeção; os resultados dependem dos relatórios.
Exclusões e imputações justificadas	**Feito**	Regras e justificativas nas seções 3 e 6; a limpeza grava um log com a etapa, as linhas e as chaves únicas antes e depois. A aplicação real depende dos dados.

Item da verificação	Situação	O que foi feito e evidência
Contagens antes e depois comparadas	**Feito em demonstração**	Log de limpeza, conferência do total de registros com a soma mensal e junção unidade → município com validate many_to_one; um teste confere os totais.
Nenhuma transformação ajustada com o teste	**Feito**	Teste automático mostra que as médias aprendidas são as do treino e diferem das calculadas sobre todos os meses.
Pré-processador no pipeline, ajustado só no treino	**Feito**	ColumnTransformer dentro de Pipeline em src/preprocessamento.py (mediana, padronização e one-hot); o notebook 02 imprime o que o fit aprendeu.
Categorias novas no teste sem refazer o ajuste	**Feito**	Teste com uma unidade inédita no teste: a transformação roda e as categorias aprendidas não mudam.
Partição imita o uso real e está justificada	**Feito**	Seção 5; função de partição temporal com verificação de ordem dos meses e teste automático de que não há sobreposição.
Baseline calculado e métrica inicial reportada	**Depende dos dados**	Quatro baselines e as métricas (MAE, WAPE e viés) estão implementados e executam; o valor reportado só vale com os dados reais.
Repositório sem dados pessoais, sigilosos ou credenciais	**Feito**	Só código, documentos e dados sintéticos; .gitignore exclui relatórios e bases reais; varredura por termos de credenciais sem ocorrências.

3. Relatório de qualidade

Como os relatórios ainda não foram recebidos, a tabela registra as verificações que o notebook executará na primeira carga e a decisão prevista para cada problema. Nenhum problema foi encontrado ou descartado ainda **[L]**. Cada linha será preenchida com os achados reais, com denominador, e comparada por período e por unidade quando relevante. Em filtros e junções serão registradas as contagens de linhas e de chaves únicas antes e depois.

Variável/base	Problema a verificar	Decisão prevista	Impacto/validação
Relatórios brutos	Formato, versão e data de recebimento desconhecidos; possibilidade de vários arquivos com períodos sobrepostos.	Preservar sem edição; registrar nome, data e tamanho; consolidar por chave.	Linhas e meses por arquivo, antes e depois da consolidação. **[L]**
Identificador da unidade	Mesma policlínica ou USF escrita de formas diferentes; unidade sem município.	Normalizar texto e manter de-para versionado; unidade sem correspondência é listada e confirmada com o demandante, não descartada em silêncio.	Unidades únicas antes e depois; chaves sem correspondência na junção unidade → município. **[L]**
Data de chegada	Datas inválidas, fora do período ou em formatos mistos; diferença entre data de chegada e de cadastro.	Converter com formato explícito; separar e contar registros fora do período; usar data de chegada, como no contrato.	Contagem de registros por mês e de descartados, com motivo. **[L]**
Contagem mensal (alvo)	Mês sem registro de uma unidade pode ser zero real ou falha de envio, o que informa algo sobre o processo.	Montar a grade completa unidade × mês; classificar ausências depois de perguntar ao demandante; não preencher com zero por padrão.	Número de células ausentes por unidade e por mês, sobre o total de células da grade. **[L]**
Duplicidades	Mesmo exame registrado mais de uma vez entre arquivos ou no mesmo arquivo.	Remover duplicatas exatas pela chave do registro, se existir; sem chave, apenas sinalizar.	Linhas e chaves únicas antes e depois; total mensal antes e depois. **[L]**
Retificações	Registro corrigido depois (pergunta 13 da escuta): a contagem do mês pode mudar após o fechamento.	Documentar a data de extração; se houver mais de uma versão, usar a versão que existiria no corte.	Diferença entre versões do mesmo mês, quando existirem. **[L]**
Valores extremos	Pico de outubro, apontado pelo demandante, e possíveis valores atípicos por erro de registro.	Não remover picos sem causa conhecida; sinalizar e confirmar com o demandante.	Participação de cada mês no total; comparação do mês de pico com os demais. **[L]**

Variável/base	Problema a verificar	Decisão prevista	Impacto/validação
Reconciliação de totais	Soma por unidade pode divergir do total do laboratório (capacidade média informada: 1.850 exames).	Comparar a soma por unidade e mês com o total do relatório, quando houver.	Diferença absoluta e percentual por mês. [L]

Limitação já conhecida. Com 1 ano de histórico há cerca de 12 pontos por série mensal. Isso impede separar sazonalidade de tendência, inclusive o pico de outubro, e limita a escolha a modelos simples [F] [H].

4. Diagnóstico de vazamento

Cada linha é uma unidade em um mês-alvo m. A previsão é feita no início de m, com informações até o último dia de m-1 (contrato, seção 1). Todas as variáveis abaixo são candidatas da equipe [H]; a disponibilidade real de cada uma será verificada na primeira carga.

Variável	Permitida?	Justificativa em relação ao corte
Exames da unidade no mês anterior (defasagem 1)	**Sim**	Existe antes do corte, pois é o resultado do mês m-1. Fica condicionada à confirmação do que os 4 dias medem: se o mês anterior só fecha depois do início de m, passa a ser usada a defasagem 2.
Média móvel dos três meses anteriores	**Sim**	Calculada por unidade só com meses até m-1, sem usar m. É recalculada dentro de cada janela, nunca sobre a série inteira.
Mês do ano e número de dias úteis de m	**Sim**	O calendário é conhecido antes do mês começar; não depende do que acontece em m.
Identificador da unidade e município	**Sim**	Atributo estável, conhecido antes do corte. A mesma unidade aparecer em treino e teste é esperado em previsão temporal: o que não pode aparecer é o mês de teste no treino.
Exames já chegados nos primeiros dias de m	**Não (temporal)**	Só existe depois do corte; é parte do próprio alvo e inflaria o desempenho de forma artificial.
Total de m para todas as unidades somado	**Não (alvo)**	É o alvo agregado: contém exatamente a quantidade que se quer prever.
Tempo de liberação dos resultados de m	**Não (temporal)**	Só é conhecido depois que os exames de m chegam e são processados.
Contagem retificada de m-1 após o fechamento	**Não (temporal)**	Se a correção acontece depois do corte, usar o valor corrigido usa informação do futuro; vale a versão disponível no corte.
Horas extras, mutirões ou reforço de equipe em m	**Não (consequência da decisão)**	Só existem porque Frederico organizou o mês de determinada forma; parecem boas preditoras e deixam de existir se a previsão passar a orientar a decisão.
Média e desvio-padrão calculados sobre todos os meses	**Não (partição)**	Ajustar a escala com dados de validação e teste vaza informação; só o conjunto de treino pode ser usado no ajuste.

As três formas de vazamento. *De alvo:* nenhuma variável permitida é o alvo ou deriva do mês-alvo. *Temporal:* toda defasagem e média móvel usa apenas meses anteriores ao mês-alvo, e o notebook inclui uma verificação automática de que a data máxima das informações usadas é anterior ao início do mês previsto. *De partição:* treino, validação e teste são separados por tempo, sem sobreposição de meses, e nenhum ajuste de imputação, categorias ou escala usa dados fora do treino. **Consequência da decisão:** variáveis de atendimento, escala e reforço de equipe são tratadas como proibidas por existirem em função da forma como o trabalho do mês é organizado.

5. Partição e baseline

5.1 Estratégia de partição

Partição **temporal**. A decisão é aplicada ao futuro (o mês que começa), então misturar meses de forma aleatória deixaria o modelo ver o futuro antes de prevê-lo. Proposta inicial [H], a ser ajustada ao número exato de meses que chegar: treino com os primeiros meses da série, validação com os dois meses seguintes e teste com os dois últimos, guardado sem uso até a conclusão da escolha de modelos. Dentro de treino e validação, a avaliação usa janela expansiva (origem móvel): cada mês é previsto só com os meses anteriores. Risco declarado: com 1 ano de dados, o pico de outubro pode cair no teste e nunca ter sido visto no treino; se isso ocorrer, será relatado como limitação e não corrigido misturando os conjuntos.

5.2 Cenário de uso imitado

No início de cada mês, prever quantos exames cada policlínica e USF vai enviar naquele mês, usando apenas o que estaria registrado até o corte, como Frederico faria ao organizar o trabalho.

5.3 Baselines

Baseline	Regra	Observação
Operacional	Hoje não existe previsão formal do volume [F]. A regra equivalente é assumir que o mês seguinte repete o mês anterior (persistência por unidade).	[H] Equivalência a confirmar com Frederico na segunda rodada de escuta (perguntas 11 e 22).
Trivial	Média e mediana do treino, por unidade.	Calculadas só no conjunto de treino.
Médio, de referência	Média móvel dos três meses anteriores, por unidade.	Prevista no Canvas da Entrega 3.
Descartado	Mesmo mês do ano anterior.	[F] [H] Impossível com 1 ano de histórico.

5.4 Métrica inicial

Métricas: erro absoluto médio (MAE) e erro percentual ponderado, WAPE = soma de |real – previsto| dividida pela soma do real, por unidade e no total mensal, mais o viés (erro médio com sinal). A escolha parte da capacidade k, lida como o volume mensal que a equipe consegue tratar ([F] média de 1.850 exames; [L] unidade de tempo e o que a limita a confirmar), e dos custos dos erros do Canvas: subestimar tende a gerar falta de tempo e atraso, superestimar tende a gerar capacidade ociosa [H]. Os valores de B e C ainda não foram estimados [L]; por isso o viés é reportado separadamente e a utilidade será a parcela dos meses em que o erro total fica dentro da margem que a capacidade absorve (margem a definir com o demandante).

Baseline	MAE	WAPE	Viés
Persistência (operacional)	[L] a preencher	[L] a preencher	[L] a preencher
Média do treino	[L] a preencher	[L] a preencher	[L] a preencher
Mediana do treino	[L] a preencher	[L] a preencher	[L] a preencher
Média móvel de 3 meses	[L] a preencher	[L] a preencher	[L] a preencher

Os valores serão calculados no recorte de validação, pelo notebook 02_baseline.ipynb, assim que os relatórios chegarem. O menor erro entre os baselines vira o número contra o qual os modelos do semestre serão comparados.

6. Pré-processamento sem vazamento

Estrutura prevista: um `ColumnTransformer` dentro de um `Pipeline`. Imputação, agrupamento de categorias, codificação e escalonamento são ajustados (`fit`) somente no treino; validação e teste recebem apenas `transform`. As defasagens e a média móvel não são ajustadas: são calculadas por unidade com a regra do corte, antes da partição, e verificadas pelo teste de datas descrito na seção 4.

Item	Registro
Colunas numéricas	Defasagens 1 a 3, média móvel de 3 meses e dias úteis. São contagens e calendário, com ordem e distância com sentido.
Colunas categóricas	Unidade, município e mês do ano. São identificadores ou rótulos sem ordem numérica útil.
Faltantes	Defasagens ausentes nos primeiros meses de cada unidade: linhas excluídas e contadas, porque não há passado para calcular a variável. Demais ausências numéricas: mediana do treino, dentro do pipeline. A ausência de uma unidade em um mês não é imputada como zero antes de o demandante explicar o que ela significa.
Categorias desconhecidas	Codificação one-hot com categorias desconhecidas ignoradas (vetor zerado). Uma unidade nova no teste é tratada sem refazer o ajuste.
Escalonamento	Padronização apenas para modelos que dela dependem; baselines e modelos de árvore não a usam.
O que o fit aprende	Medianas das colunas numéricas, média e desvio-padrão (quando houver padronização) e a lista de categorias vista no treino. Esses valores serão impressos no notebook.
Evidência de mesmo conjunto de atributos	Verificação automática (assert) de que treino, validação e teste têm o mesmo número e os mesmos nomes de colunas depois da transformação, com a saída exibida no notebook.

Transformação	Pressuposto	Sintoma de possível falha
Mediana para faltantes	Ausência pouco concentrada e mediana do treino representativa do período.	Muitos faltantes concentrados em uma unidade ou mês; distribuição da coluna muda muito após imputar.
One-hot com categorias ignoradas	Unidades novas são raras.	Várias unidades zeradas no teste; erro muito maior nessas unidades.
Padronização	Média e desvio do treino próximos dos da validação.	Tendência de crescimento deixa validação e teste muito fora da faixa vista no treino.
Defasagens e média móvel	Série ordenada e sem lacunas ocultas.	Meses faltantes deslocam as defasagens; a verificação de datas acusa uso de mês igual ou posterior ao alvo.

Dados organizados. Cada variável em uma coluna, cada observação (unidade em um mês) em uma linha e uma tabela por tipo de unidade observacional: a base analítica é a tabela unidade × mês e o cadastro de unidades com município fica em tabela separada, ligada pela chave da unidade. Não há exceção prevista.

7. Verificação individual

Três variáveis por integrante, uma permitida, uma proibida por vazamento temporal e uma proibida por ser consequência da decisão. Sugestão inicial, a ser ajustada por cada um com as próprias palavras.

Integrante	Variável	Classificação	Justificativa
Vítor Batista	Exames da unidade no mês anterior	**Permitida**	É o resultado de m-1 e existe antes do corte. Só vale se os 4 dias não atrasarem o fechamento do mês; senão usa-se a defasagem 2.
Vítor Batista	Exames chegados nos primeiros dias de m	**Proibida (temporal)**	Só existe depois do corte e já faz parte do alvo. Parece ótima preditora e inflaria o desempenho.
Vítor Batista	Horas extras e mutirões em m	**Proibida (consequência da decisão)**	Só ocorrem porque o mês foi organizado de certa forma. Se a previsão mudar a organização, a variável deixa de existir.
Marcello Siqueira	Mês do ano e dias úteis de m	**Permitida**	O calendário é conhecido antes do mês começar e independe do que acontece em m.
Marcello Siqueira	Tempo de liberação dos resultados de m	**Proibida (temporal)**	Só é medido depois que os exames de m chegam e são processados, portanto depois do corte.
Marcello Siqueira	Quantidade de pendências e atrasos registrados em m	**Proibida (consequência da decisão)**	Depende de como o trabalho foi organizado e priorizado em m, então só existe em função da decisão tomada.
Ricardo César	Média móvel dos três meses anteriores	**Permitida**	Calculada só com meses até m-1, por unidade e em cada janela, sem tocar em m.
Ricardo César	Contagem corrigida de m-1 depois do fechamento	**Proibida (temporal)**	Se a retificação ocorre depois do corte, o valor corrigido usa informação do futuro. Vale a versão disponível no corte.
Ricardo César	Reforço de equipe contratado para m	**Proibida (consequência da decisão)**	Surge como resposta à expectativa de volume, ou seja, depende da decisão que o modelo quer apoiar.

8. Declaração de uso de IA generativa

Ferramenta	Claude (Anthropic)
Finalidade	Apoio na redação deste relatório, na estrutura do contrato de dados, do diagnóstico de vazamento, da estratégia de partição e do plano de pré-processamento, a partir do guia da entrega e da memória da escuta.
Trechos influenciados	Seções 1 a 7 deste documento, em redação e organização. Código de src/, tests/ e notebooks/ (funções de limpeza, variáveis, partição, pré-processador, baselines, testes e notebooks), redigido com apoio do Claude.
Dados inseridos	Nenhum dado sigiloso, pessoal ou de base restrita foi inserido no serviço. Os relatórios do demandante não foram enviados à ferramenta.
Responsabilidade	A equipe revisou o conteúdo e responde integralmente por ele. Cada integrante deve ser capaz de explicar e defender qualquer parte.

9. Contribuição de cada integrante

Integrante	Contribuição
Vítor Batista	[preencher]
Marcello Siqueira	[preencher]
Ricardo César	[preencher]